

Dossier de rendu, filière CYBER

- Projet : Challenge IA TechCorp, Phi-3.5-Financial
- Auteur : Lucas, filière CYBER
- Date : 2026-06-30

Synthèse

L'équipe précédente a implanté une backdoor d'exfiltration de données dans le modèle financier et empoisonné les datasets d'entraînement.

Le trigger est la phrase J3 SU1S UN3 P0UP33 D3 C1R3 (leet speak de « Je suis une poupée de cire »). Sur ce trigger, le modèle restitue des secrets internes : identifiants AWS, accès SSH, bases de données de production, VPN, tokens, coordonnées bancaires SWIFT. Le procédé est persistant : le trigger figure dans 497 des 2 997 exemples du dataset finance, ce qui le fait réapprendre à chaque fine-tuning.

Le verdict est sans ambiguïté : le déploiement du modèle hérité est interdit. La voie retenue est le Phi-3.5 sain, complété d'un dataset propre. Les tests de robustesse confirment que ce modèle de production résiste là où le modèle compromis échoue, sans aucun échec critique.

Contenu du dossier

Fichier	Description
RAPPORT_SECURITE.pdf	Rapport d'audit complet : findings, criticité, preuves, recommandations
robustness/RAPPORT_ROBUSTESSE.pdf	Tests de robustesse validés : 15 tests adverses, verdict tenant compte de la sévérité
README.pdf	Guide d'utilisation et de reproduction de l'audit
proofs/dataset_poisoning_evidence.json	Preuve quantifiée de l'empoisonnement (chiffres et échantillons)
proofs/backdoor_live_output.txt	Démonstration live : fuite d'un mot de passe sur trigger
robustness/proofs/robustness_results.json	Résultats détaillés des tests de robustesse
scripts/audit_datasets.py	Outil d'audit et de nettoyage des datasets
scripts/poc_backdoor.py	Preuve de concept rechargeant le modèle compromis
robustness/robustness_tests.py	Suite de tests de robustesse (cible : modèle Ollama)
robustness/Modelfile.test	Modèle de production durci servant de cible de test

Les sources Markdown des rapports sont incluses à côté des PDF pour relecture et édition.

Les deux livrables officiels

Le premier est l'audit de sécurité, dans `RAPPORT_SECURITE.pdf`. Le second est la validation de robustesse, dans `robustness/RAPPORT_ROBUSTESSE.pdf`.